Основы технологии CUDA

Семинар 4:Работа с глобальной памятью

Автор курса:

- Казённов Андрей

Типы памяти в CUDA

Тип памяти	Доступ	Уровень выделения	Скорость работы
Регистры	R/W	Per-thread	Высокая(on-chip)
Локальная	R/W	Per-thread	Низкая (DRAM)
Shared	R/W	Per-block	Высокая(on-chip)
Глобальная	**R/W**	**Per-grid**	**Низкая (DRAM)**
Constant	R/O	Per-grid	Высокая(L1 cache)
Texture	R/O	Per-grid	Высокая(L1 cache)

Функции для работы с глобальной памятью

- cudaError_t **cudaMalloc** (void ** **devPtr**, size_t **size**); *Выделение **size** памяти на устройстве и записывание адреса в **devPtr***

- cudaError_t **cudaMallocPitch** (void ** **devPtr**, size_t * **pitch**, size_t **width**, size_t **height**);

*Выделение памяти под двухмерный массив размером **width * height**, возвращает указатель **devPtr** на память и смещение для каждой строки **pitch***

- cudaError_t **cudaFree** (void * **devPtr**);

*Освобождение памяти по адресу **devPtr** на устройстве*

- cudaError_t cudaMemset (void* devPtr, int value, size_t count);

Заполнение памяти по адресу devPtr значениями value на размер count

Функции для работы с глобальной памятью

- cudaError_t **cudaMemcpy** (void * dst, const void * src, size_t count, enum cudaMemcpyKind kind);

Копирование данных между устройством и хостом

dst *– указатель на память приемник*

src *– указатель на память источник*

count *– размер копируемой памяти в байтах*

kind *– направление копирования может принимать значения:*

  - ***cudaMemcpyHostToDevice*** *– с хоста на устройство*
  - ***cudaMemcpyDeviceToHost*** *– с устройства на хост*
  - ***cudaMemcpyDeviceToDevice*** *– с устройства на устройство*
  - ***cudaMemcpyHostToHost*** *– с хоста на хост*

- cudaError_t cudaMemcpyAsync (void * dst, const void * src, size_t count, enum cudaMemcpyKind kind, cudaStream_t stream);

Аналогично ***cudaMemcpy*** *только асинхронно в потоке* ***stream***

Стандартная схема работы с глобальной памятью

```
float * devPtr;            // pointer device memory
                           // allocate device memory
cudaMalloc ( (void **) &devPtr, 256*sizeof ( float );

                           // copy data from host to device memory
cudaMemcpy ( devPtr, hostPtr, 256*sizeof ( float ),
cudaMemcpyHostToDevice );

                            // process data

                            // copy results from device to host
cudaMemcpy ( hostPtr, devPtr, 256*sizeof( float ),
cudaMemcpyDeviceToHost );

                            // free device memory
cudaFree   ( devPtr );
```

Сборка CUDA программ

nvcc file.cu –o file.o

В нашем курсе все примеры имеют CmakeList.txt

cmake . & make

Доступ к вычислительной машине

ssh -p 15136 user@hpc.mipt.ru

Рабочие файлы примеров

/opt/hpcschool/cuda

Все примеры копировать в свою рабочую папку!!!

Пример: Нахождение числа Пи

- Пример лежит в файле pi.cu
- Ядро занимается расчетом площади трапеций
- Суммирование полученных площадей производится на хосте
- => Необходимо создать массив для передачи данных с устройства на хост

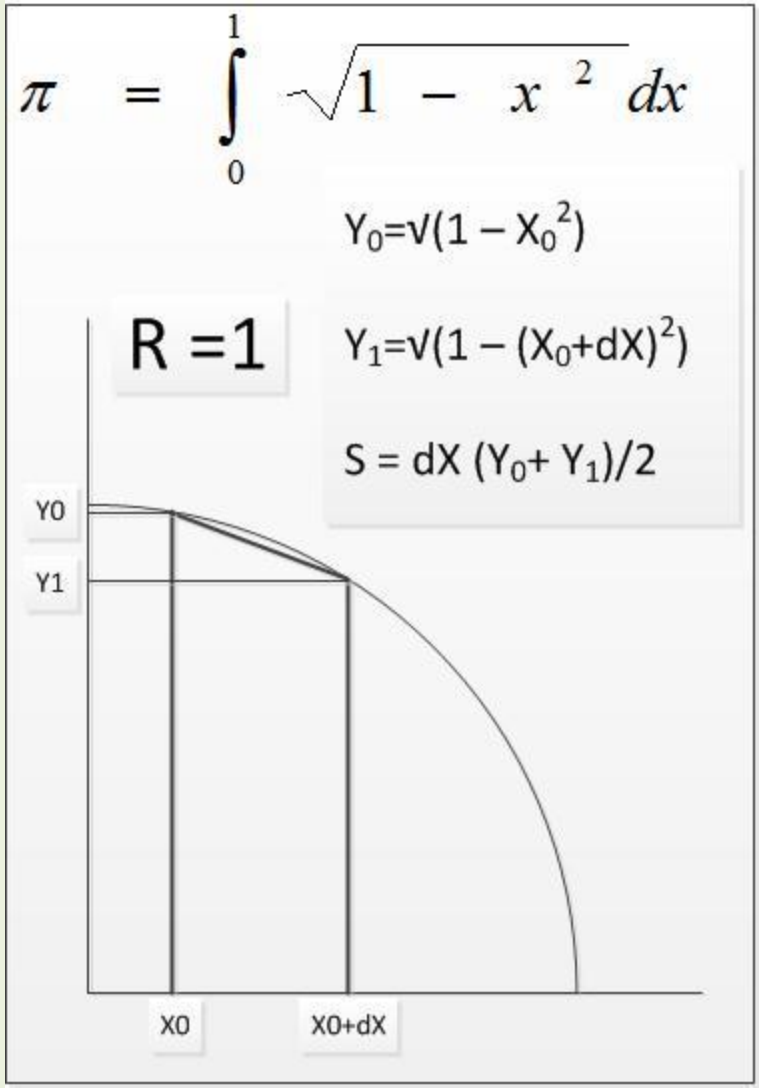

Пример: Нахождение числа Пи: Ядро

```
__global__ void pi_kern(CUDA_FLOAT *res)
{
        int n = threadIdx.x + blockIdx.x * BLOCK_SIZE;
        CUDA_FLOAT x0 = n * 1.f / (BLOCK_SIZE * GRID_SIZE); // Начало
отрезка интегрирования
        CUDA_FLOAT y0 = sqrtf(1 - x0 * x0);
        CUDA_FLOAT dx = 1.f / (1.f * BLOCK_SIZE * GRID_SIZE *
THREAD_SIZE); // Шаг интегрирования
        CUDA_FLOAT s = 0; // Значение интеграла по отрезку, данному
текущему треду
        CUDA_FLOAT x1, y1;
        for (int i=0; i < THREAD_SIZE; ++i)
        {
                x1 = x0 + dx;
                y1 = sqrtf(1 - x1 * x1);
                s += (y0 + y1) * dx / 2.f;   // Площадь трапеции
                x0 = x1; y0 = y1;
        }
        res[n] = s;    // Запись результата в глобальную память
}
```

Пример: Нахождение числа Пи: Main

Смотрите в примере на сервере

Задача №1: Нахождение центра масс четверти круга

$$X_{cm} = \frac{\int_0^1 x\sqrt{1-x^2}\,dx}{\int_0^1 \sqrt{1-x^2}\,dx}$$

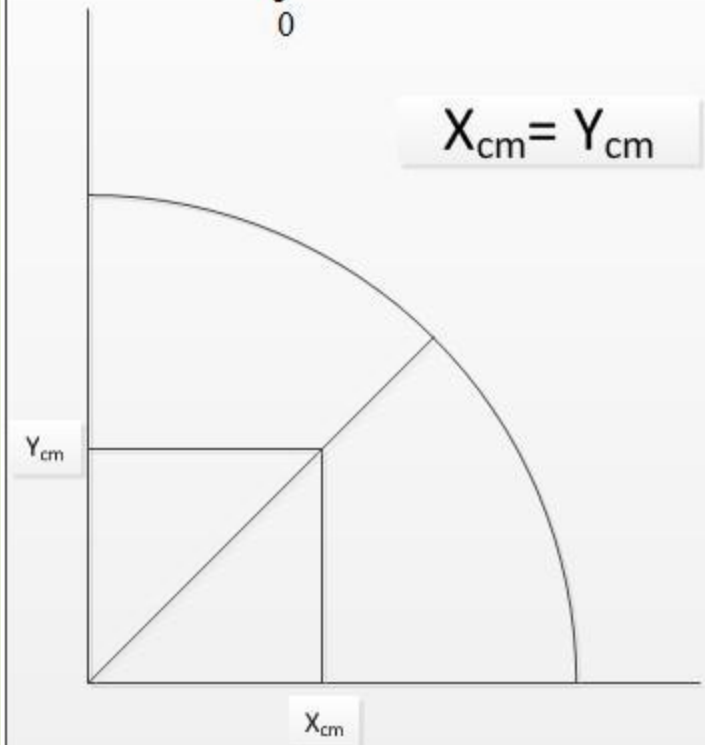

- Можно добавить ещё один массив в параметры ядра и записать результат второго интеграла в него
- Можно написать самостоятельное второе ядро
- Найдите Xcm?!

Ресурсы курса

Сайт: HPC.MIPT.RU

Раздел образование

Автор курса:

Казённов Андрей

- E-mail: kazennov@gmail.com
- ICQ: 622774